

Masked Language Modeling

Gary Briceño

- Ingeniero Electronico
- Universidad Nacional de Ingeniería - Perú
- Estudiante de la Maestría de IA
- Universidad de los Andes - Colombia

Enlaces:

- <https://www.linkedin.com/in/garybriceno/>
- <https://github.com/GaryBriceno>





¿Qué es Masked Language Modeling (MLM)?

MLM es una tarea de **pre entrenamiento** que permite a un modelo de lenguaje como **BERT** aprender el contexto **bidireccional** de una palabra dentro de una oración.



Motivación

Modelos tradicionales como GPT leen el texto de **izquierda a derecha**, por lo que una palabra solo ve su contexto previo.

Pero muchas tareas de NLP (como la respuesta a preguntas) requieren entender el **contexto completo** (antes y después de una palabra).

Traditional/Causal Language Models

The **cat** _____ the tree.

Masked Language Models

The cat _____ **the tree.**



¿Cómo funciona MLM?

1) Tienes una oración:

“El perro juega en el parque”

2) Selecciona aleatoriamente algunas palabras para enmascarar (approx 15%):

“El [MASK] juega en el parque”

3) El modelo intenta predecir la palabra original (“perro”) usando el contexto de ambos lados.

4) La predicción se entrena con un softmax sobre el vocabulario completo.

Diferencias con un Modelo de Lenguaje tradicional

Tipo de modelo	Direccion	Ejemplo
GPG/RNN Tradicional	Unidireccional (izq → der)	“El perro juega en ... “
BERT (con MLM)	Bidireccional	“El [MASK] juega en el parque

- Gracias a MLM, BERT puede entender relaciones más ricas entre palabras.

Ref:

- Paper relativo a BERT: <https://arxiv.org/pdf/1810.04805v2>



Detalles técnicos del MLM en BERT

Cuando se seleccionan tokens para enmascarar:

- 80% se reemplaza por [MASK]
- 10% por una palabra aleatoria
- 10% no se modifican

Esto permite que el modelo no dependa siempre del token [MASK], ya que no existe en tareas reales.



Ventajas de MLM

- Permite representaciones contextuales profundas
- Mejora el rendimiento en tareas como clasificación, respuesta a preguntas, NER (Named Entity Recognition)
- Aprende de texto sin etiquetas (auto-supervisado)